机器学习基本概念笔记

一. 机器学习基本概念

什么是机器学习

机器学习模拟人类通过经验判断事情。

对于计算机而言，经验即通过数据形式存在，计算机利用数据产生学习算法，把有效数据联系起来找寻数据中的规律。在之后遇到新的判断物中，可以通过学习算法来将他定义与归类。

了解以下概念

监督学习

即有标准答案的学习。

模型从带标签的数据里面进行学习，就像身边有一个随时告诉你问题同时给你正确答案的老师，这种学习的主要作用是分类与回归。

分类的结果是离散的，主要是帮新数据找自己的类别，输出的是标签；回归的结果是连续的，输出的是数值。

无监督学习

即没有标准答案的学习。

模型会收到一堆杂乱的数据，需要通过自己去发现数据之间的结构与规律，进而对数据进行判断。这种学习的主要作用是聚类。但只是通过数据将他们分类，并不清楚每个分类的定义是什么。

聚类输出的是组别，但是这些组别都没有具体的定义。

强化学习

模型在训练过程中不断受到来自外界的反馈。

所以训练ai一定要是三种学习共同作用的，无监督学习培养自学能力，监督学习提供正确的答案与方向，强化学习让ai可以坚持学下去。

训练集

即数据，是模型学习的信息

验证集

验证模型的学习效果，并且帮助模型去调整自己对于数据的处理策略。

测试集

对模型进行测试，判断模型是否可以公正稳定的处理信息，同时在测试的时候，以前所训练的数据不会展现，这就要看模型对于学习算法的训练是否到位，相当于闭卷考试。

拟合

即模型学习数据规律的过程。

按照欠佳的测试效果可以将拟合分为两种：过拟合与欠拟合。

过拟合是指学习能力过于强大，把数据集里面和多不一般的规律都学到了，包括噪声等信息，或者是学的太死板，把数据集里面所有信息都学到了之后，并没有总结出一般性的规律，导致模型在测试的时候表现很差。

欠拟合是指，模型还没有学完数据集，所以在进行测试的时候表现很差，因为他连数据的基本规律都没有找到。

泛化

即模型的新数据的适应能力。

与过拟合相反，拥有强的泛化能力的模型对于数据有很好的举一反三的能力。

数据评估指标

1. R方值

是用于量化模型预测与真实数据之间拟合程度的指标。其值范围在 0 到 1 之间。

（1）R 方值接近0表明模型的预测与真实值之间几乎没有关系。

（2）R 方值接近1表示模型解释了数据中的大部分变化，即模型的预测与真实值非常接近。

需要注意，高 R 方值并不一定意味着模型具有好的预测能力，特别是在存在过拟合的情况下。

R 方值过低，可能表示模型拟合得不好，或者数据中的变化主要由随机噪声引起，而非模型能够解释的系统性规律。

在比较不同模型的 R 方值时，需要注意数据的规模和特征。对于具有不同规模或特征的数据集，即使 R 方值相同，也可能表示模型具有不同的拟合能力。

$y_i = \hat{y}_i + e_i$

（y_i是真实值，$\hat{y}_i$是预测值，e_i是残差）

$e_i = y_i - \hat{y}_i$

$y_i - \bar{y} = (\hat{y}_i - \bar{y}) + e_i$

$\Sigma(y_i - \bar{y})^2 = \Sigma[(\hat{y}_i - \bar{y}) + e_i]^2$

展开：

$\Sigma(y_i - \bar{y})^2 = \Sigma(\hat{y}_i - \bar{y})^2 + 2\Sigma(\hat{y}_i - \bar{y})e_i + \Sigma e_i^2$

在线性回归中（$\Sigma e_i = 0$，$\Sigma \hat{y}_i e_i = 0$）$\Rightarrow \Sigma(\hat{y}_i - \bar{y})e_i = 0$

$$\underbrace{\Sigma(y_i - \bar{y})^2}_{SST} = \underbrace{\Sigma(\hat{y}_i - \bar{y})^2}_{SSR} + \underbrace{\Sigma(y_i - \hat{y}_i)^2}_{SSE}$$

总平方和	回归平方和	残差平方和.
总波动	模型可解释的波动	不可解释的波动

2. 平均绝对误差值MAE

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

预测值与实际值之差的绝对值的平均数，取值越小，模型准确度越高。

- 直观易懂：MAE 是一个直观且易于理解的指标，因为它以与原始数据相同的单位来衡量误差。
- 对异常值不敏感：由于 MAE 取的是绝对误差的平均值，因此它对数据中的异常值或极端值不敏感。这意味着即使数据中存在一些异常值，MAE 值也不会受到太大的影响。
- 评估预测精度：MAE 直接反映了模型的预测精度，因为它衡量的是预测值与真实值之间的平均绝对差异。较小的 MAE 值表示模型具有更高的预测准确性。
- 不受数据集规模影响：MAE 是一个相对稳定的指标，它不受数据集规模的影响。因此，无论是在小数据集还是大数据集上，MAE 都可以提供一致的评估结果。

3. 均方误差MSE

$$\text{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

预测值与实际值之差的平方的平均值。取值越小，模型准确度越高。

- 敏感性：MSE 对预测误差的大小非常敏感，即使是较小的误差也会对 MSE 值产生较大的影响。因此，它能够有效反映模型的预测能力。
- 计算简单：MSE 的计算公式相对简单，易于理解和实现。
- 对离群值敏感：MSE 的一个主要缺点是它对数据中的离群值非常敏感。如果数据集中存在离群值，MSE 的值可能会受到显著影响，导致对模型性能的评估不准确。

4. 均方误差根RMSE

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

取值越小，模型准确度越高。

- 敏感性：RMSE 对预测误差的大小非常敏感，即使是较小的误差也会对 RMSE 值产生较大的影响。这有助于发现模型中的小偏差。
- 量纲一致性：RMSE 的单位与原始数据的单位相同，便于理解和解释。
- 对离群值敏感：由于 RMSE 计算中涉及到平方操作，因此它对数据中的离群值非常敏感。如果数据集中存在离群值，RMSE 的值可能会受到显著影响。
- 数值范围：RMSE 的取值范围是 0 到正无穷大。数值越小，表示模型的预测精度越高。

5. 中位数绝对误差MAD

中位数绝对偏差适用于单变量的样本数据，是一种稳健的异常值检测方法。

对样本数据中的异常值更加具有弹性，能够降低异常值对样本数据的影响。因此，常采用 MAD 方法进行异常值检测。中位数对于数据集中的极端值的影响较小，最后将得出的异常值通过中位数进行替代。

6. 平均绝对百分误差MAPE

$$\text{MAPE} = \frac{1}{n}\sum_{i=1}^{n}\left|\frac{\hat{y}_i - y_i}{y_i}\right| \times 100\%$$

预测值与实际值之差的绝对值与实际值之比的平均数，以百分比表示。取值越小，模型准确度越高。

MAPE 取值范围是 0 到正无穷大。在这个范围内，MAPE 值越小，预测精度越高。

- MAPE 值小于 10%：通常认为预测精度较高。

- MAPE 值在 10%-20% 之间：预测精度仍然可以接受，但可能需要进行一些优化以提高准确性。

- MAPE 值大于 20%：这表示预测效果不太理想，可能需要重新评估模型或寻找更好的预测方法。

7. 可解释差分EVS

可解释方差得分（EVS）是衡量回归模型预测结果与实际结果之间方差相似度的一个指标。它反映了模型捕捉到的数据变异性的程度，即模型预测值的变化与实际值变化之间的相似度。

可释方差得分的取值范围为 [0,1]，当 EVS 为 1 时，表示模型完美预测了数据；当 EVS 为 0 时，表示模型无法解释数据方差。

在实际应用中，EVS 通常用于比较不同模型的表现，取值越接近 1，表示模型解释的数据方差越多，表现越好。

8. 均方根对数误差MSLE

计算的是预测值与实际值之间的对数差的平方的平均值，再取平方根。

- 敏感性：MSLE 对于预测值与实际值之间的比例误差非常敏感。当预测值与实际值相差很大时，即使它们的绝对值差异可能不大，MSLE 也会给出一个较大的值，从而惩罚模型。

- 对数据的分布敏感：由于 MSLE 涉及到对数运算，因此它对数据的分布非常敏感。如果数据中存在大量的极端值或离群点，那么 MSLE 可能会给出不稳定的结果。